

Introduction à la segmentation d'images

Yann Gousseau

Crédits Julie Delon
Cours 4IM01

Segmentation : une première définition

Definition

Segmenter une image = la diviser en **régions homogènes**, pour un ou plusieurs attributs donnés (niveau de gris, couleur, texture, etc).

On appelle **contours** (ou **bords**) de l'image les frontières entre ces régions.

Dualité Contours / Régions.

« Gestaltists and psychophysicists agree that such a segmentation process is at work at the very first stages of the visual perception process. In addition they proved that these first stages are highly independent of any learning or a priori knowledge of the world. »

Variational Methods in Image Segmentation, J.-M. Morel et S. Solimini, Birkhäuser, 1995.

Dualité contours / régions

- **Contours** : généralement obtenus par opérateurs différentiels courbes au travers desquelles l'information change brusquement (discontinuités)
- **Régions** : un problème de classification des pixels groupes de pixels partageant des caractéristiques communes (niveau de gris, couleur, texture, etc.)



Construction des objets visuels

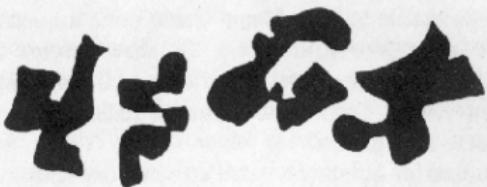


FIG. 1.2. Oggetti visivi sconosciuti, senza significato, ma perfettamente visibili e stabili per forma, colore, grandezza, rapporti spaziali.

Quels sont les lois, principes gouvernant la perception des formes et la construction visuelle des objets ?

→ complément sur les lois de groupement visuel et la Gestalt

Construction des objets visuels



Quels sont les lois, principes gouvernant la perception des formes et la construction visuelle des objets ?

→ complément sur les lois de groupement visuel et la Gestalt

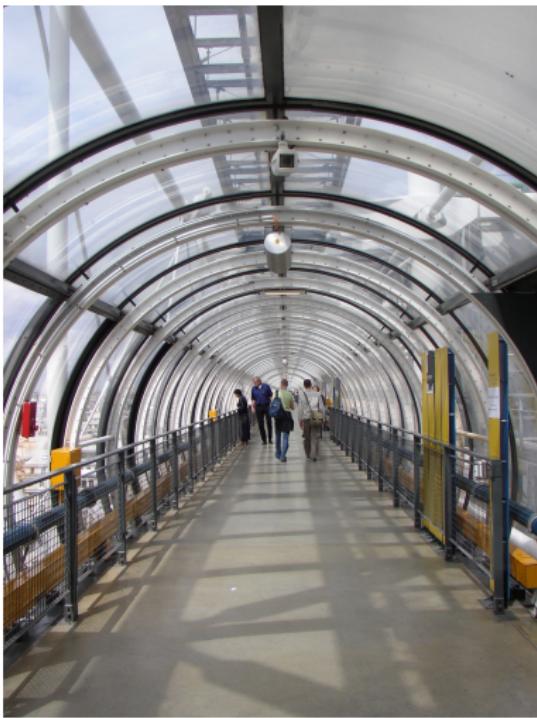
Un problème mal posé

La notion de bonne segmentation/bonne détection de contours dépend fortement du type d'image à traiter et des applications envisagées.

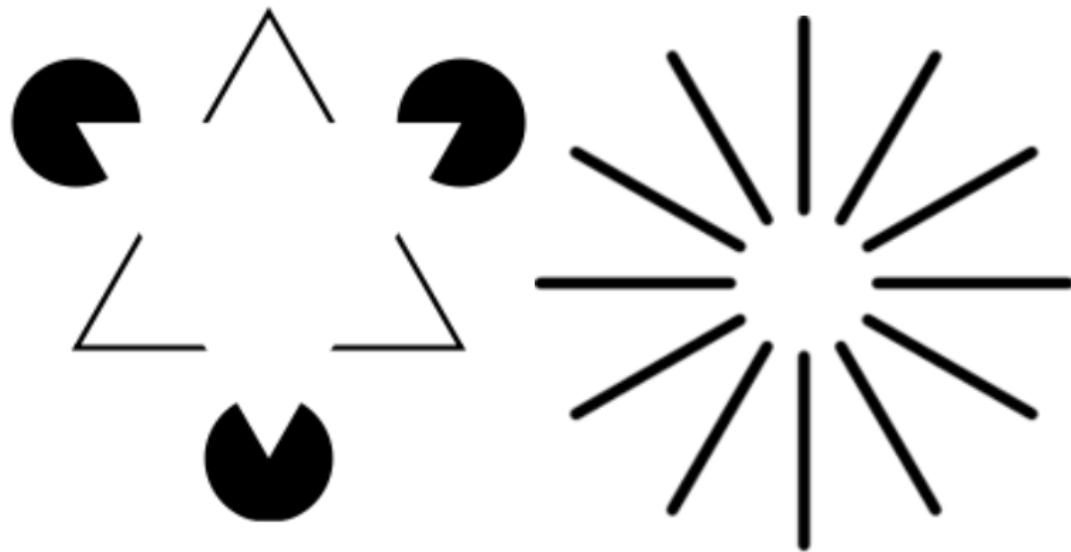
Un problème mal posé



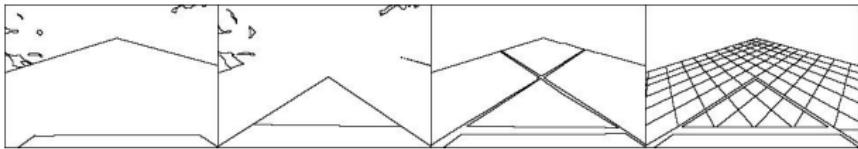
Un problème mal posé



Un problème mal posé

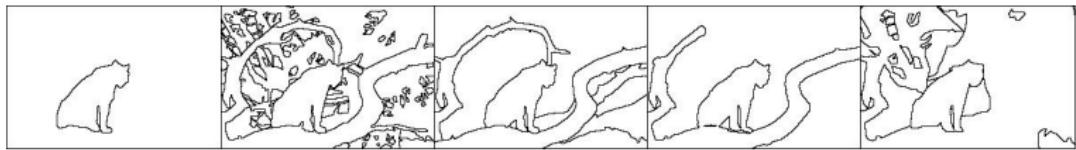


Problème mal posé



Base empirique de segmentations faites à la main, disponibles sur le site
<http://www.eecs.berkeley.edu/Research/Projects/CS/vision/grouping/segbench/>
Martin et al., ICCV 2001

Problème mal posé



Base empirique de segmentations faites à la main, disponibles sur le site
<http://www.eecs.berkeley.edu/Research/Projects/CS/vision/grouping/segbench/>
Martin et al., ICCV 2001

Panorama des méthodes de segmentation

Approches “contours”

- Opérateurs différentiels pour la détection de contours : Marr-Hildreth, Haralick, Canny, etc. ([aujourd'hui](#)) ;
- Contours actifs, *snakes*, level sets ([→ IM04](#)) ;
- Ligne de partage des eaux ([→ cours morphologie mathématique IM01](#)) ;

Panorama des méthodes de segmentation

Approches “contours”

- Opérateurs différentiels pour la détection de contours : Marr-Hildreth, Haralick, Canny, etc. ([aujourd'hui](#)) ;
- Contours actifs, *snakes*, level sets (\rightarrow [IM04](#)) ;
- Ligne de partage des eaux (\rightarrow [cours morphologie mathématique IM01](#)) ;

Approches “régions”

- Méthodes de segmentation globales : segmentation d'histogrammes, k-means, mean-shift, etc. ([aujourd'hui](#)) ;
- Méthodes par transformation de région : Region Growing, Split and Merge ;
- Optimisation globale de type Graph-Cuts sur l'ensemble des régions (\rightarrow [IM03](#)) ;
- Classification bayésienne (\rightarrow [IM03](#)) ;

Panorama des méthodes de segmentation

Approches “contours”

- Opérateurs différentiels pour la détection de contours : Marr-Hildreth, Haralick, Canny, etc. ([aujourd'hui](#)) ;
- Contours actifs, *snakes*, level sets (\rightarrow [IM04](#)) ;
- Ligne de partage des eaux (\rightarrow [cours morphologie mathématique IM01](#)) ;

Approches “régions”

- Méthodes de segmentation globales : segmentation d'histogrammes, k-means, mean-shift, etc. ([aujourd'hui](#)) ;
- Méthodes par transformation de région : Region Growing, Split and Merge ;
- Optimisation globale de type Graph-Cuts sur l'ensemble des régions (\rightarrow [IM03](#)) ;
- Classification bayésienne (\rightarrow [IM03](#)) ;

Approches “mixtes”

- Méthodes variationnelles contours-régions (modèle de Mumford Shah)

Panorama des méthodes de segmentation

Approches “contours”

- Opérateurs différentiels pour la détection de contours : Marr-Hildreth, Haralick, Canny, etc. ([aujourd'hui](#)) ;
- Contours actifs, *snakes*, level sets (\rightarrow [IM04](#)) ;
- Ligne de partage des eaux (\rightarrow [cours morphologie mathématique IM01](#)) ;

Approches “régions”

- Méthodes de segmentation globales : segmentation d'histogrammes, k-means, mean-shift, etc. ([aujourd'hui](#)) ;
- Méthodes par transformation de région : Region Growing, Split and Merge ;
- Optimisation globale de type Graph-Cuts sur l'ensemble des régions (\rightarrow [IM03](#)) ;
- Classification bayésienne (\rightarrow [IM03](#)) ;

Approches “mixtes”

- Méthodes variationnelles contours-régions (modèle de Mumford Shah)

Réseaux convolutionnels profonds

- Segmentation d'instances, sémantique, panoptique, etc. ([introduction](#) \rightarrow [cours détection objets IM01](#)) ;

Panorama des méthodes de segmentation

Approches “contours”

- Opérateurs différentiels pour la détection de contours : Marr-Hildreth, Haralick, Canny, etc. ([aujourd'hui](#)) ;
- Contours actifs, *snakes*, level sets (\rightarrow [IM04](#)) ;
- Ligne de partage des eaux (\rightarrow [cours morphologie mathématique IM01](#)) ;

Approches “régions”

- Méthodes de segmentation globales : segmentation d'histogrammes, k-means, mean-shift, etc. ([aujourd'hui](#)) ;
- Méthodes par transformation de région : Region Growing, Split and Merge ;
- Optimisation globale de type Graph-Cuts sur l'ensemble des régions (\rightarrow [IM03](#)) ;
- Classification bayésienne (\rightarrow [IM03](#)) ;

Approches “mixtes”

- Méthodes variationnelles contours-régions (modèle de Mumford Shah)

Réseaux convolutionnels profonds

- Segmentation d'instances, sémantique, panoptique, etc. ([introduction](#) \rightarrow [cours détection objets IM01](#)) ;

Beaucoup de ces méthodes sont testables en ligne sur le site IPOL

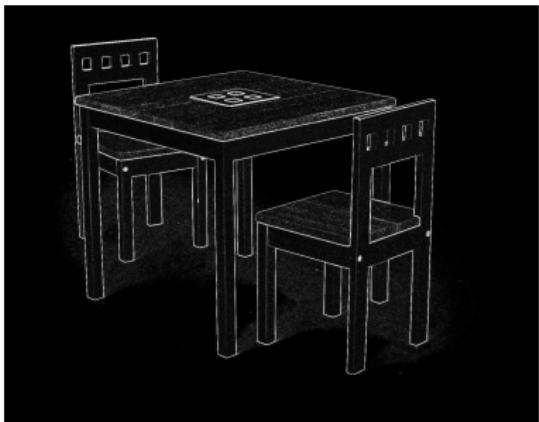
www.ipol.im

Première partie I

Méthodes classiques de détection de contours

Méthodes de détection de contours

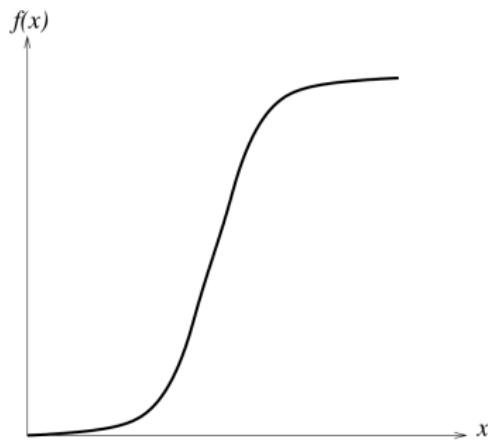
Approches classiques basées sur les propriétés locales des bords (dérivées 1ère et 2nde de l'image).



Gauche : image originale /

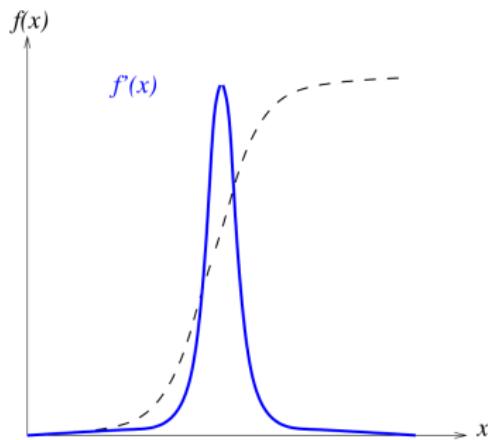
Droite : module du gradient de l'image $|\nabla I|$ (valeurs les plus élevées en clair)

Contour idéal dans le cas continu 1D



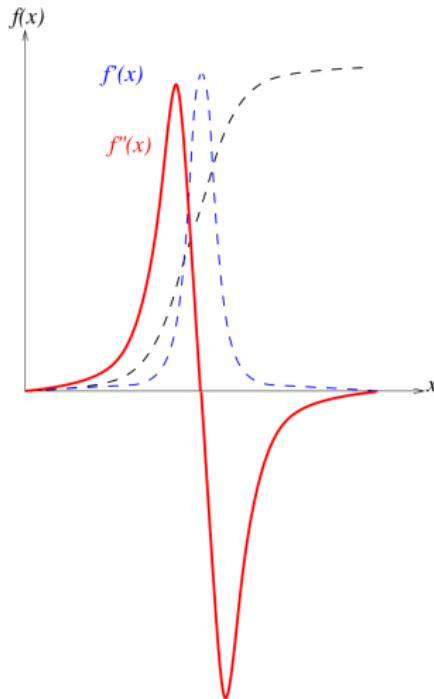
La position du contours correspond au point de plus grande pente.

Contour idéal dans le cas continu : dérivée première



Ce qui correspond au maximum de la dérivée première

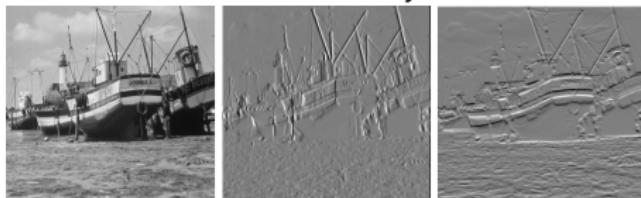
Contour idéal dans le cas continu : dérivée seconde



Ce qui correspond au passage par zéro de la dérivée deuxième

Dimension 2 : le gradient

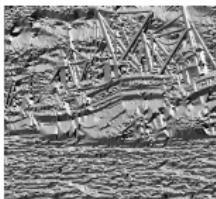
- Pour I une image, on note $I_x = \frac{\partial I}{\partial x}$ et $I_y = \frac{\partial I}{\partial y}$,



- En chaque point, le gradient $\nabla I = \begin{pmatrix} I_x \\ I_y \end{pmatrix}$ est un vecteur perpendiculaire aux contours
- Sa norme $|\nabla I| = \sqrt{I_x^2 + I_y^2}$ indique l'intensité du contour



- $\theta = \arctan\left(\frac{I_y}{I_x}\right)$ est l'orientation du gradient



L'approximation discrète la plus simple est

$$I_x(i, j) = I(i + 1, j) - I(i, j),$$

$$I_y(i, j) = I(i, j + 1) - I(i, j).$$

Méthodes de détection de contours

Approche naïve : regarder les points où le gradient est fort, $|\nabla I| > \lambda$.

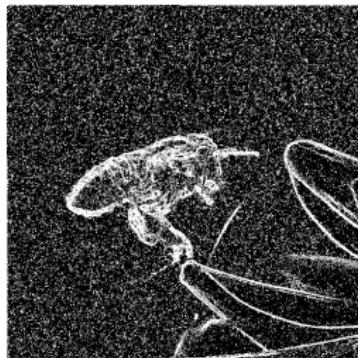


I , $|\nabla I|$ et indicatrice de $\{x; |\nabla I(x)| > 10\}$.

Méthodes de détection de contours

Approche naïve : regarder les points où le gradient est fort, $|\nabla I| > \lambda$.

Pas pratique : donne des régions plutôt que des courbes et très sensible au bruit.



Même chose après ajout d'un bruit gaussien d'écart-type 10.

Méthodes de détection de contours

Approche naïve : regarder les points où le gradient est fort, $|\nabla I| > \lambda$.

Pas pratique : donne des régions plutôt que des courbes et très sensible au bruit.

Solution : Préfiltrage obligatoire pour éviter de détecter du bruit, des textures etc.
(caractère oscillatoire de l'image).

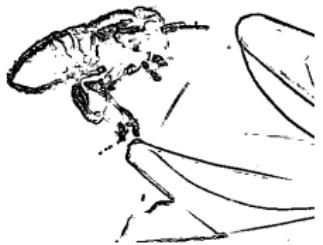


Après convolution par un filtre gaussien d'écart-type 2.

Alternative : le filtrage de Sobel

Le filtre de Sobel est défini par

$$S_x(I) = \begin{pmatrix} 1 & 0 & -1 \\ 2 & 0 & -2 \\ 1 & 0 & -1 \end{pmatrix} * I \quad S_y(I) = \begin{pmatrix} 1 & 2 & 1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{pmatrix} * I$$



Passages par zéro du Laplacien [Marr-Hildreth, 1980]

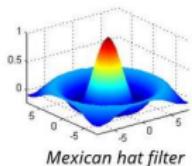
- ➊ points où $\Delta(G_\sigma * I)$ change de signe (*zero-crossing*).

Méthodes de détection de contours

Passages par zéro du Laplacien [Marr-Hildreth, 1980]

- ➊ points où $\Delta(G_\sigma * I)$ change de signe (*zero-crossing*).

Remarque 1 : $\Delta(G_\sigma * I) = (\Delta G_\sigma) * I$
pas besoin de dériver → filtre “en chapeau mexicain”

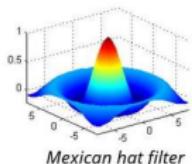


Mexican hat filter

Passages par zéro du Laplacien [Marr-Hildreth, 1980]

- ① points où $\Delta(G_\sigma * I)$ change de signe (*zero-crossing*).

Remarque 1 : $\Delta(G_\sigma * I) = (\Delta G_\sigma) * I$
pas besoin de dériver → filtre “en chapeau mexicain”



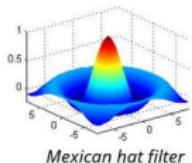
- ② on sélectionne les points où $|\nabla I| \geq \sigma_1$

Méthodes de détection de contours

Passages par zéro du Laplacien [Marr-Hildreth, 1980]

- ① points où $\Delta(G_\sigma * I)$ change de signe (*zero-crossing*).

Remarque 1 : $\Delta(G_\sigma * I) = (\Delta G_\sigma) * I$
pas besoin de dériver → filtre “en chapeau mexicain”



- ② on sélectionne les points où $|\nabla I| \geq \sigma_1$

Remarque 2 : Le laplacien peut être approché par une différence de Gaussiennes :

$$\Delta G_\sigma = \frac{1}{\sigma} \frac{\partial G_\sigma}{\partial \sigma}.$$

→ cours sur les points clés

Marr, D. and Hildreth, "Theory of Edge Detection", *Proceedings of the Royal Society of London B*, vol 207 : 187-217.
1980

Passages par zéro du laplacien

Second ordre : I et $\Delta G_\sigma * I$ pour $\sigma = 2$.



Passages par zéro du laplacien

Passages par 0 du Laplacien



Passages par zéro du laplacien

Restriction aux points où la norme du gradient est supérieure à 10.



[Algorithme de Canny]

Extrema du module du gradient dans la direction du gradient

- ➊ passe-bas $I_\sigma = G_\sigma * I$

[Algorithme de Canny]

Extrema du module du gradient dans la direction du gradient

- ① passe-bas $I_\sigma = G_\sigma * I$
- ② maximas locaux de $|\nabla I_\sigma|$ dans la direction de ∇I_σ

[Algorithme de Canny]

Extrema du module du gradient dans la direction du gradient

- ① passe-bas $I_\sigma = G_\sigma * I$
- ② maximas locaux de $|\nabla I_\sigma|$ dans la direction de ∇I_σ

Remarque : cela revient à chercher les passages par zéro de $D^2 I(\nabla I, \nabla I)$.

[Algorithme de Canny]

Extrema du module du gradient dans la direction du gradient

- ① passe-bas $I_\sigma = G_\sigma * I$
- ② maximas locaux de $|\nabla I_\sigma|$ dans la direction de ∇I_σ

Remarque : cela revient à chercher les passages par zéro de $D^2 I(\nabla I, \nabla I)$.

- ③ hysteresis
 - on sélectionne les points $E_1 = \{x : |\nabla I|(x) \geq \sigma_1\}$
 - on garde les points de E_1 connectés à au moins un point de $E_2 = \{x : |\nabla I|(x) \geq \sigma_2\}$

Notation :

$$D^2(\nabla I, \nabla I) = (I_x \quad I_y) \begin{pmatrix} I_{xx} & I_{xy} \\ I_{xy} & I_{yy} \end{pmatrix} \begin{pmatrix} I_x \\ I_y \end{pmatrix}$$

Canny, J., A Computational Approach To Edge Detection, *IEEE Trans. Pattern Analysis and Machine Intelligence*, 8 :679-714, 1986.

Egalement travaux de Haralick 1984, Deriche 1987

Passage par 0 de la dérivée seconde dans la direction du gradient

Second ordre : $D^2 I_\sigma(DI_\sigma, DI_\sigma)$ pour $\sigma = 2$.



Passage par 0 de la dérivée seconde dans la direction du gradient

Passages par zéro de $D^2 I_\sigma(DI_\sigma, DI_\sigma)$



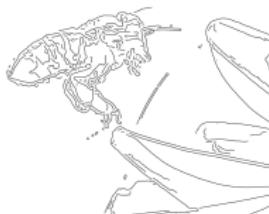
Passage par 0 de la dérivée seconde dans la direction du gradient

Restriction aux points où la norme du gradient est supérieure à 10.



Dépendance au paramètre σ

Ensemble des images I_σ quand σ varie : **espace échelle linéaire (linear scale space)**



Algorithme de Canny pour $\sigma = 0.5, 1, 2, 3$ (toutes choses égales par ailleurs)

- La valeur de σ peut-être choisie en fonction du contenu / niveau de bruit
- L'ensemble des I_σ peut être utilisé pour **analyser** les images (extrema en (x, y, σ) , variation des structures en fonction de σ , etc.) : cf cours sur les **descripteurs géométriques**

Deuxième partie II

Méthodes globales d'extraction de régions

Principe

Une segmentation de l'histogramme de niveaux de gris h_I donne une segmentation de l'image I en régions.

Ces méthodes sont globales : elles n'utilisent pas l'information spatiale sur les pixels.

Binarisation, seuillage multiniveaux supervisé ou non, mélange de gaussiennes, seuillage local, etc.

Les différentes régions de la segmentation sont données par les composantes connexes des pixels appartenant à la même classe de l'histogramme.

[B. Sankur, M. Sezgin], A Survey Over Image Thresholding Techniques And Quantitative Performance Evaluation, *Journal of Electronic Imaging*, 13(1), 146-165, January, 2004.

→ Cours de Florence Tupin (IM03)

- A priori sur les classes
- Régularisation markovienne

Méthodes par seuillage d'histogramme

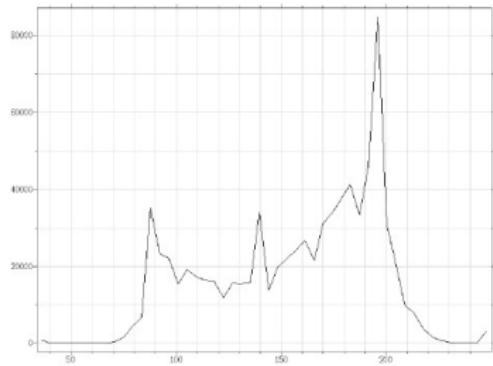
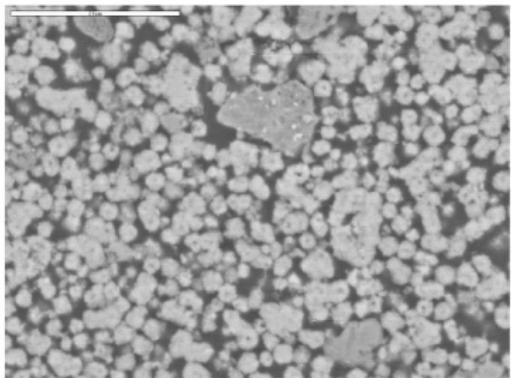
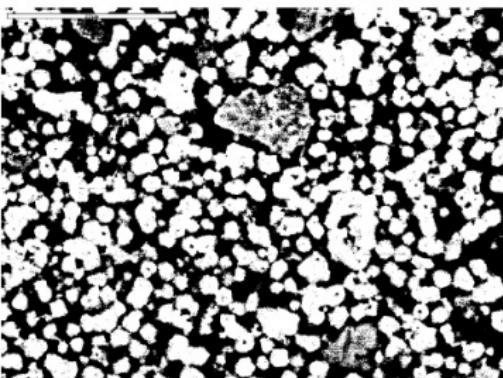
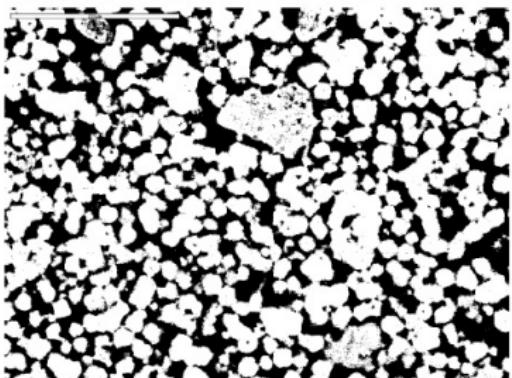
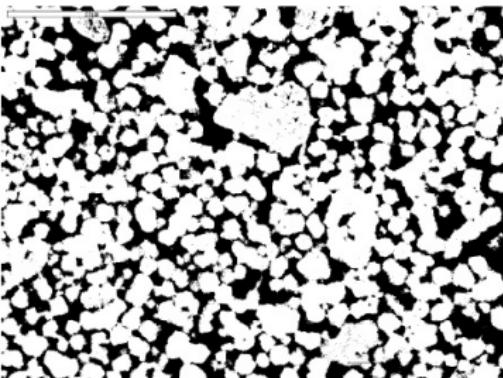
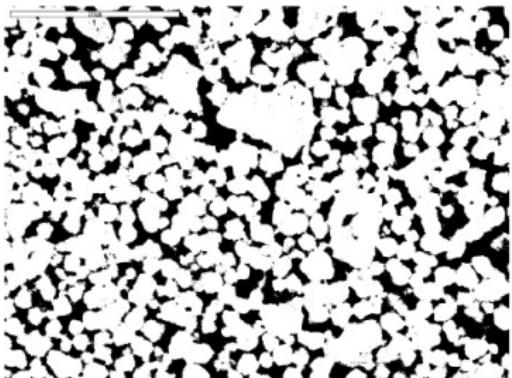


Image d'un milieu poreux et son histogramme de niveaux de gris.

Méthodes par seuillage d'histogramme

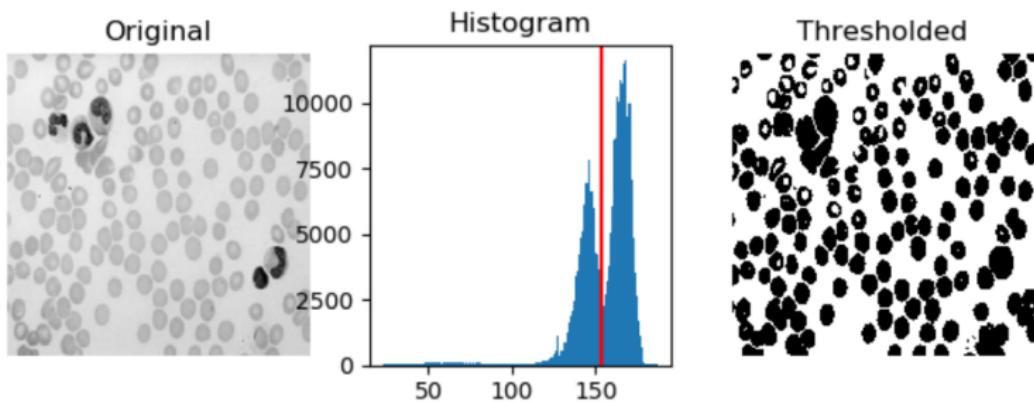


Binarisations avec seuils 135, 145, 155, 165.

Classification automatique en 2 classes : Méthode d'Otsu

Principe

Le seuil est calculé de manière à minimiser les variances intra-classes



Méthode d'Otsu

Notations : Image I , à valeurs dans $\{1, \dots, G\}$,
histogramme h_I et histogramme cumulé H_I ($H_I(n) = \sum_{i=1}^n h(i)$)

Méthode d'Otsu

Notations : Image I , à valeurs dans $\{1, \dots, G\}$,
histogramme h_I et histogramme cumulé H_I ($H_I(n) = \sum_{i=1}^n h(i)$)

Pour un **seuil** T , l'image est partagée en **deux classes** E_0 et E_1 de moyennes et variances respectivement $\mu_0(T), \mu_1(T), \sigma_0^2(T), \sigma_1^2(T)$.

Méthode d'Otsu

Notations : Image I , à valeurs dans $\{1, \dots, G\}$,
histogramme h_I et histogramme cumulé H_I ($H_I(n) = \sum_{i=1}^n h(i)$)

Pour un **seuil** T , l'image est partagée en **deux classes** E_0 et E_1 de moyennes et variances respectivement $\mu_0(T), \mu_1(T), \sigma_0^2(T), \sigma_1^2(T)$.

On définit la variance intra-classes comme

$$\sigma_w^2(T) = H(T)\sigma_0^2(T) + (1 - H(T))\sigma_1^2(T)$$

et la variance inter-classes

$$\sigma_b^2(T) = H(T)(1 - H(T))(\mu_1(T) - \mu_0(T)) = \sigma^2 - \sigma_w^2$$

Méthode d'Otsu

Notations : Image I , à valeurs dans $\{1, \dots, G\}$,
histogramme h_I et histogramme cumulé H_I ($H_I(n) = \sum_{i=1}^n h(i)$)

Pour un **seuil** T , l'image est partagée en **deux classes** E_0 et E_1 de moyennes et variances respectivement $\mu_0(T), \mu_1(T), \sigma_0^2(T), \sigma_1^2(T)$.

On définit la variance intra-classes comme

$$\sigma_w^2(T) = H(T)\sigma_0^2(T) + (1 - H(T))\sigma_1^2(T)$$

et la variance inter-classes

$$\sigma_b^2(T) = H(T)(1 - H(T))(\mu_1(T) - \mu_0(T)) = \sigma^2 - \sigma_w^2$$

Le seuil retenu est celui qui **minimise** σ_w , ou de manière équivalente qui **maximise** σ_b

On montre que

$$\sigma_b^2(T) = \frac{[\mu(G)H(T) - \mu(T)]^2}{H(T)(1 - H(T))}$$

Avec

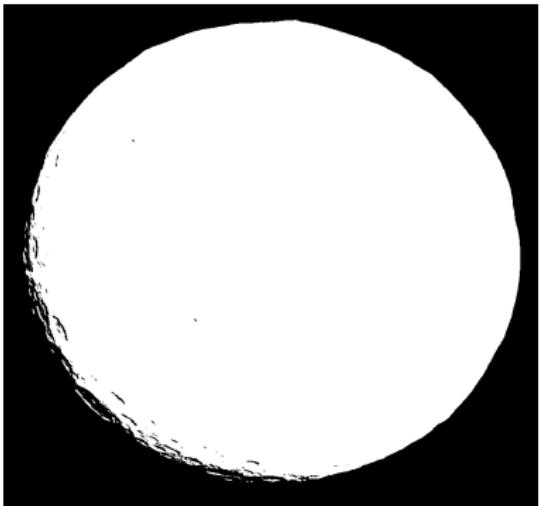
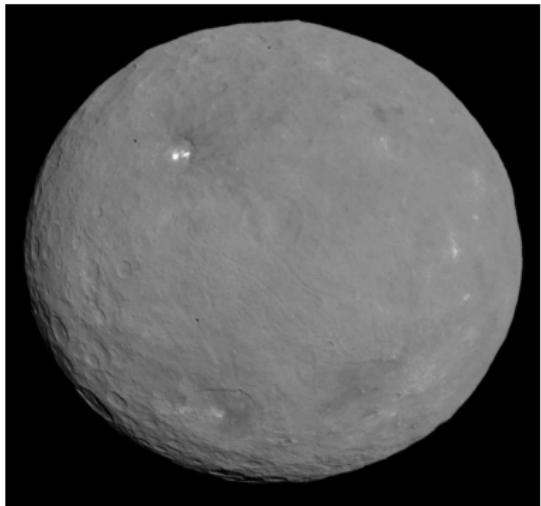
$$\mu_0(T) = H(T)^{-1} \sum_{i=0}^T ih(i)$$

$$\mu_1(T) = (1 - H(T))^{-1} \sum_{i=T+1}^G ih(i)$$

$$\sigma_0 = H(T)^{-1} \sum_{i=0}^T (i - \mu_0(T))^2 h(i)$$

$$\sigma_1 = (1 - H(T))^{-1} \sum_{i=T+1}^G (i - \mu_1(T))^2 h(i)$$

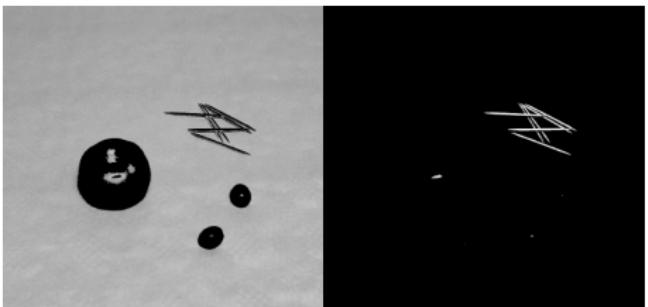
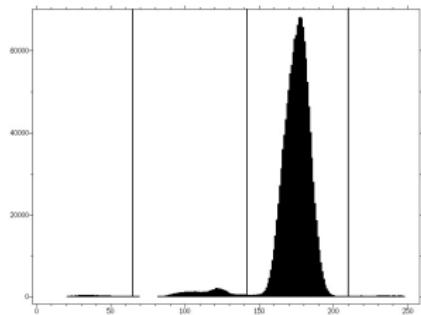
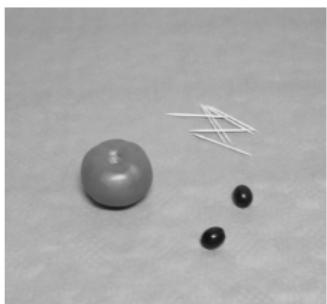
Seuillage binaire d'Otsu



Seuillage binaire d'Otsu



Extensions : segmentations des histogrammes en plusieurs classes

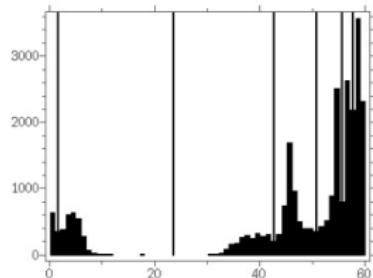


[J. Delon, A. Desolneux, J-L. Lisani et A-B. Petro], A non parametric approach for histogram segmentation, IEEE Transactions on Image Processing, vol.16, no 1, pp.253-261, Janvier 2007

Extensions : segmentations des histogrammes en plusieurs classes



(a)



(b)



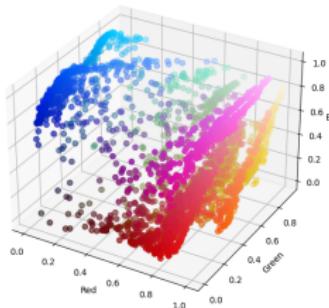
Extension simple dans le cas des images couleurs : seuillage de l'image de teinte (*Hue*).

[J. Delon, A. Desolneux, J-L. Lisani et A-B. Petro], A non parametric approach for histogram segmentation, IEEE Transactions on Image Processing, vol.16, no 1, pp.253-261, Janvier 2007

Clustering non supervisé en dimensions supérieures

La segmentation des histogrammes 1D peut-être étendue aux dimensions supérieures (couleur, texture, attributs, etc.).

L'image est représentée par un **nuage de points** en dimension n .



Une image et sa distribution de couleurs en RGB.

→ nombreuses méthodes de classification non-supervisée : k-moyennes, median-cut, mean shift, etc.

Méthodes par k-moyennes (k-means)

Données : $\{x_1, \dots, x_n\}$ points de \mathbb{R}^k ,

Paramètre : nombre de centroïdes N ,

Algorithme :

- Initialisation aléatoire des N centroïdes : $C_1, \dots, C_N \in \mathbb{R}^k$
- On itère
 - Pour $i = 1, \dots, n$, on affecte à x_i le centroïde dont il est le plus proche :

$$h(i) = \arg \min_k ||x_i - C_k||$$

- Les centroïdes sont remplacés par la moyennes des points leur correspondant : pour $k = 1, \dots, N$

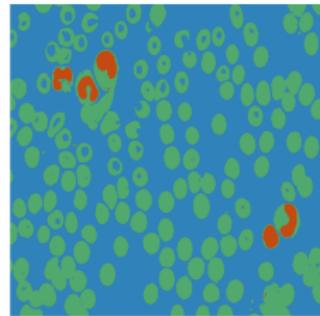
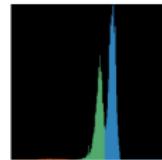
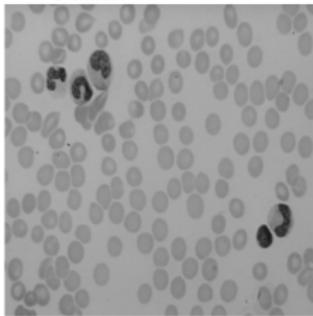
$$C_k \leftarrow \text{moyenne}\{x_i : h(i) = k\}$$

→ minimisation de la dispersion inter-classes

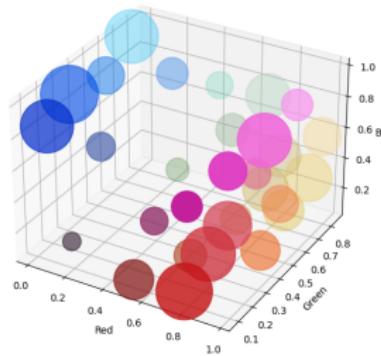
→ A tester ici : <https://www.naftaliharris.com/blog/visualizing-k-means-clustering/>

K-moyennes en 1D

3 classes



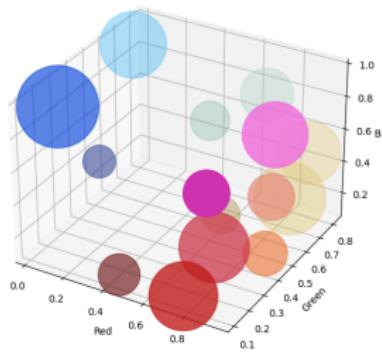
K-moyennes en 3D



Segmentation par k-moyennes RGB

30 régions

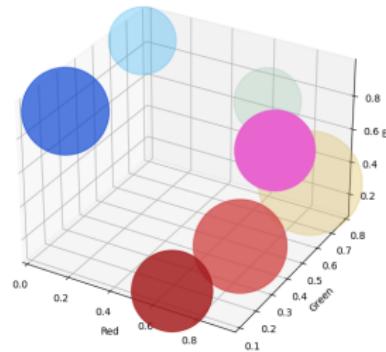
K-moyennes en 3D



Segmentation par k-moyennes RGB

15 régions

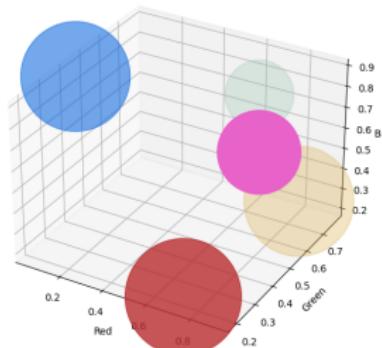
K-moyennes en 3D



Segmentation par k-moyennes RGB

7 régions

K-moyennes en 3D



Segmentation par k-moyennes RGB

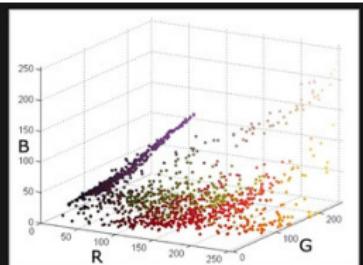
5 régions

K-moyennes en 5D

Possibilité d'ajouter les coordonnées spatiales des pixels



Input Image



Pixel RGB Color Distribution



Segmented Image
($k = 16$; $\{R, G, B\}$ -space)



Segmented Image
($k = 16$; $\{R, G, B, x, y\}$ -space)

Illustration Columbia University

Limitations de kmeans

- Nombre de clusters : paramètre critique
- Initialisation : critique
- hypothèse restrictive de distribution isotrope (circulaire)

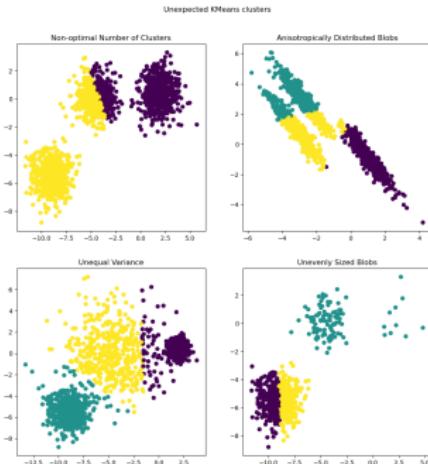


Illustration Scikit-learn

Méthode Mean Shift

Idée intuitive : les points "montent" la pente de la densité jusqu'à stabilisation ; les points sont rassemblés par "bassins d'attraction"

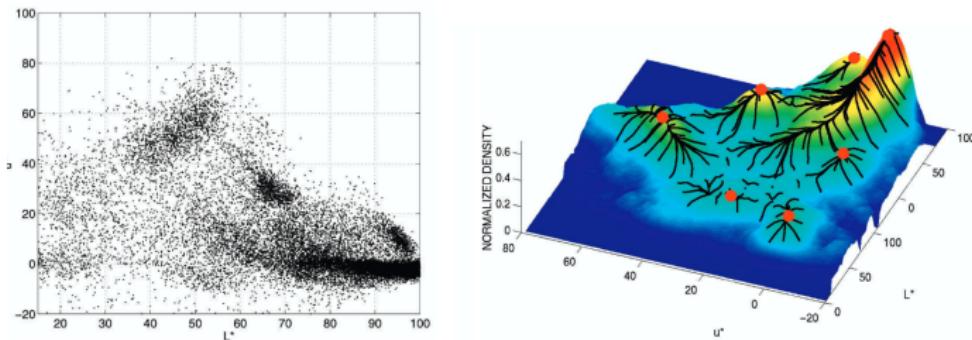
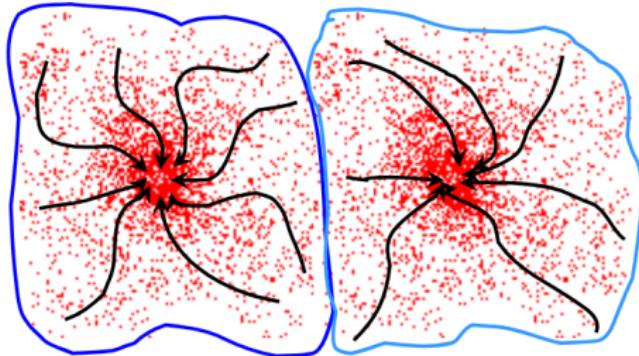


Illustration de Comaniciu - Meer 2002

[D. Comaniciu et P. Meer], Mean Shift : a robust approach toward feature space analysis, IEEE Transactions on PAMI, vol.24, no 5, pp.603-619-261, 2002

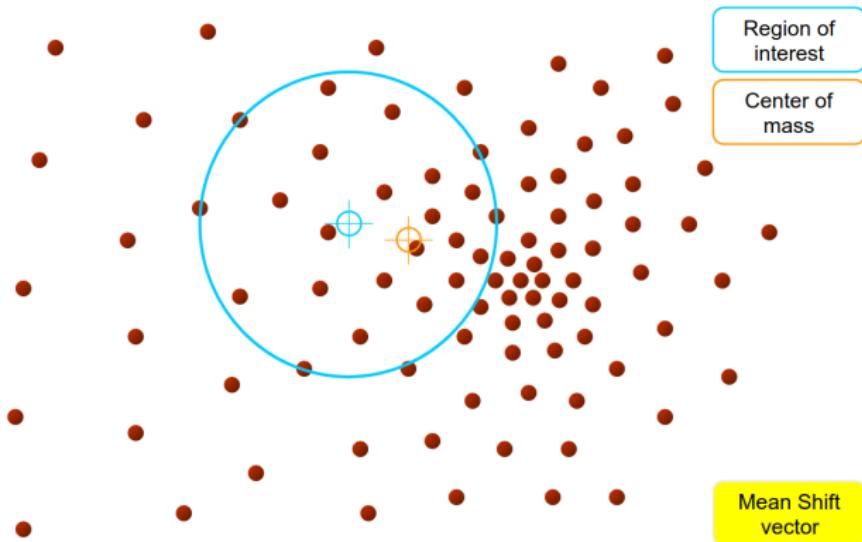
[Y. Cheng], Mean shift, mode seeking, and clustering, IEEE Transactions on PAMI, vol.17, pp.790-799, 1995

Mean Shift



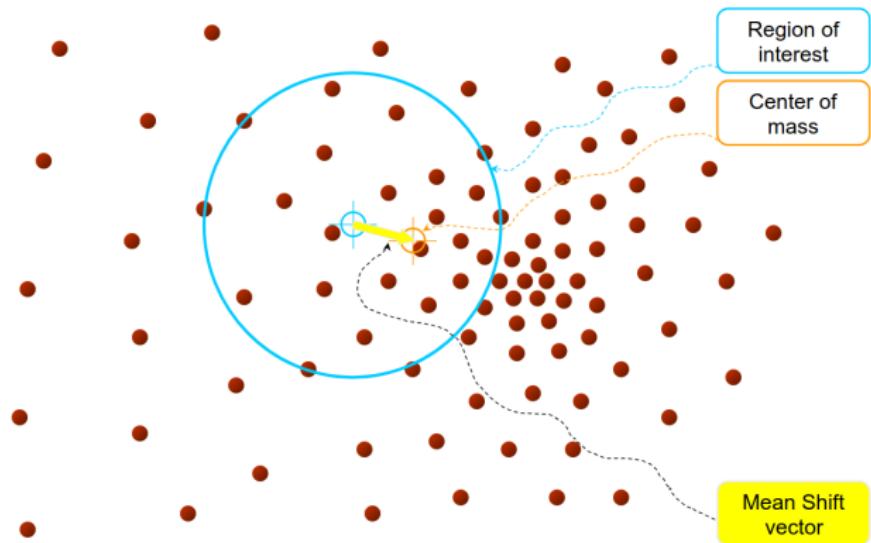
Slide by Y. Ukrainitz & B. Sarel

Mean-Shift



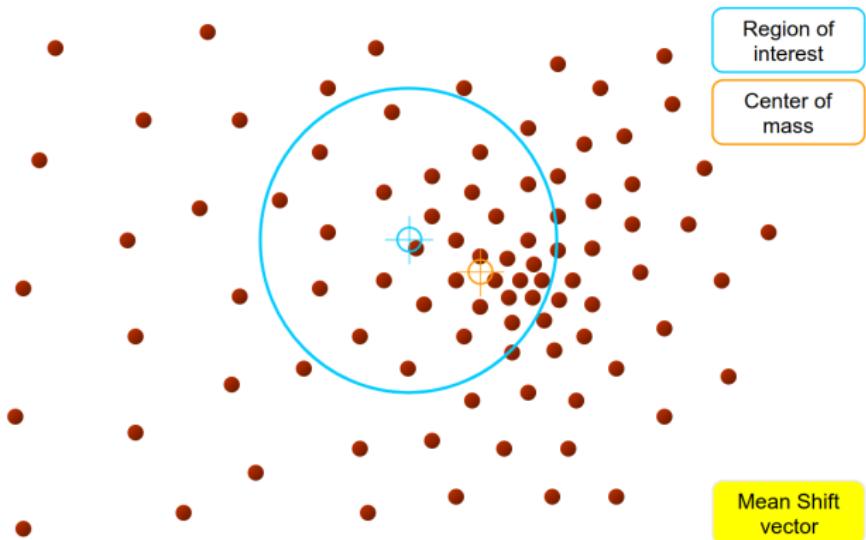
Slide by Y. Ukrainitz & B. Sarel

Mean-Shift



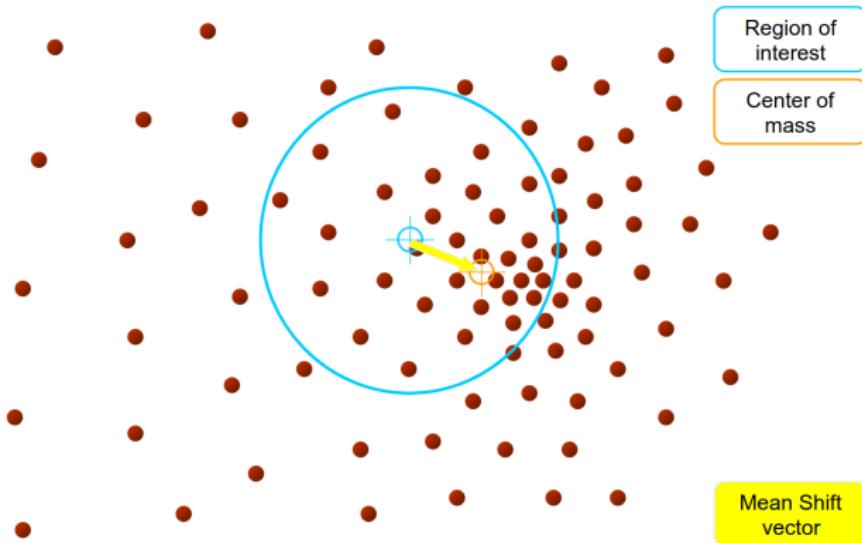
Slide by Y. Ukrainitz & B. Sarel

Mean-Shift



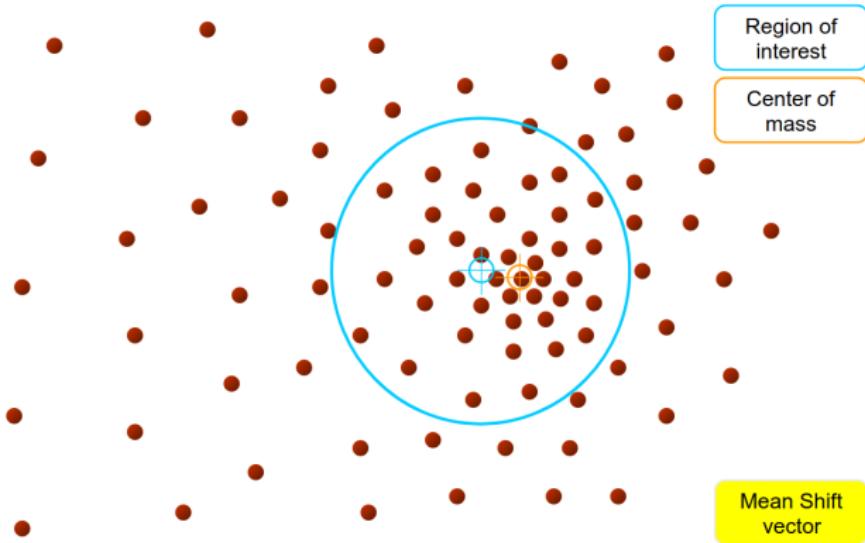
Slide by Y. Ukrainitz & B. Sarel

Mean-Shift



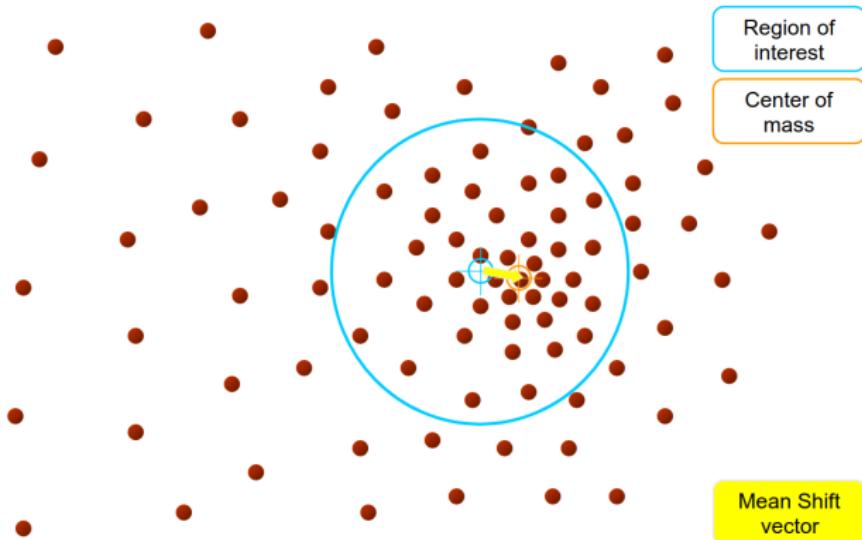
Slide by Y. Ukrainitz & B. Sarel

Mean-Shift



Slide by Y. Ukrainitz & B. Sarel

Mean-Shift



Slide by Y. Ukrainitz & B. Sarel

Algorithme Mean Shift

Soit $g_h(x)$ un noyau (e.g. $g(x) = \mathbb{1}(x \leq h)$, $g(x) = \exp(-(x/h)^2)$, etc.)

Filtrage

Données : $\{x_1, \dots, x_n\}$ points de \mathbb{R}^N ,

Paramètre : bande passante h ,

Algorithme :

Pour chaque x_i

- $y_{i,1} = x_i$
- On itère en k jusqu'à convergence vers $y_{i,fin}$ appellé *filtrage* de x_i :

$$y_{i,k+1} = \frac{\sum_{j=1}^n x_j g(|y_{i,k} - x_j|)}{\sum_{j=1}^n g(|y_{i,k} - x_j|)}$$

Algorithme Mean Shift

Soit $g_h(x)$ un noyau (e.g. $g(x) = \mathbb{1}(x \leq h)$, $g(x) = \exp(-(x/h)^2)$, etc.)

Filtrage

Données : $\{x_1, \dots, x_n\}$ points de \mathbb{R}^N ,

Paramètre : bande passante h ,

Algorithme :

Pour chaque x_i

- $y_{i,1} = x_i$
- On itère en k jusqu'à convergence vers $y_{i,fin}$ appellé *filtrage* de x_i :

$$y_{i,k+1} = \frac{\sum_{j=1}^n x_j g(|y_{i,k} - x_j|)}{\sum_{j=1}^n g(|y_{i,k} - x_j|)}$$

Segmentation

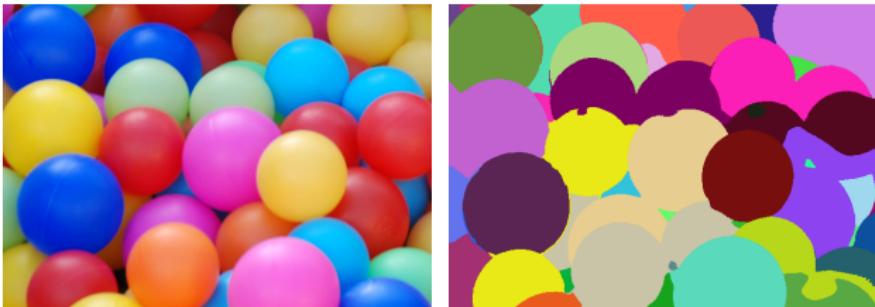
Données : $\{x_1, \dots, x_n\}$ points de \mathbb{R}^{S+C} , $x = (x^s, x^c)$ composantes spatiale et de couleur

Paramètre : bande passante $h = (h_s, h_c)$, taille minimale T

Algorithme

- Pour chaque x_i on calcule son filtrage $y_{i,fin}$ comme ci-dessus, en utilisant $g_h(x) = g_{h_s}(x^s)g_{h_c}(x^c)$
- On définit les $z_i = (x_i^s, y_{i,fin}^c)$ filtrage en couleur
- On regroupe tous les z_i à distance spatiale inférieure à h_s et distance couleur inférieure à h_c
- On supprime les régions plus petites que T

Mean Shift



Mean Shift

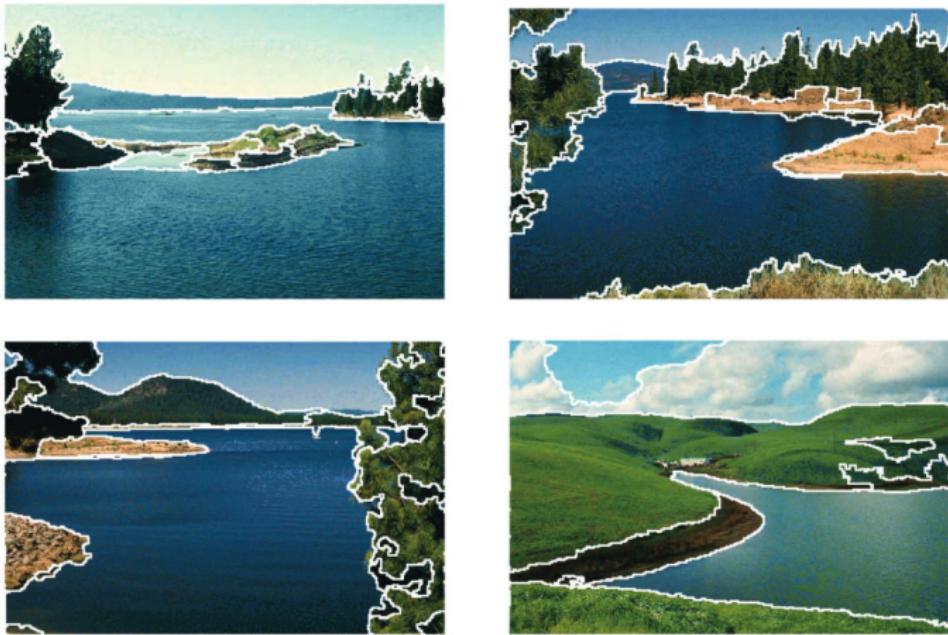
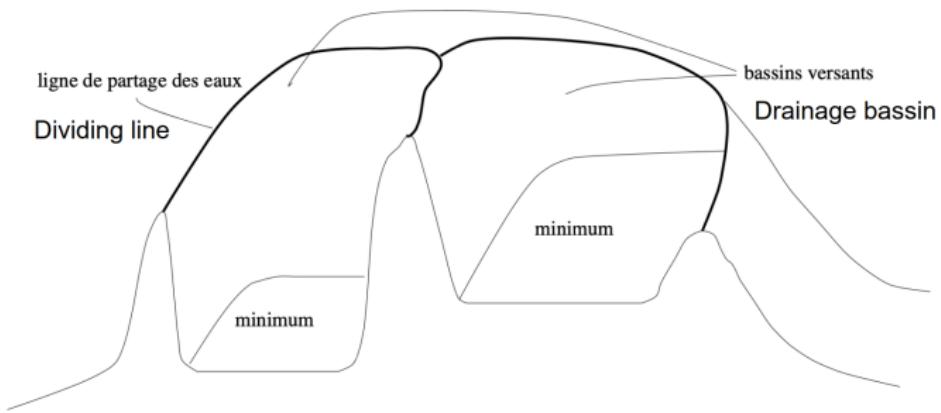


Illustration de Comaniciu - Meer 2002

Ligne de partage des eaux (watershed)

Autre algorithme "topographique" : la ligne de partage des eaux
→ **Cours de morphologie mathématique (IM01)**

Watershed dividing line



Troisième partie III

Méthodes de type “region-growing”

Principe général

Croissance de région :

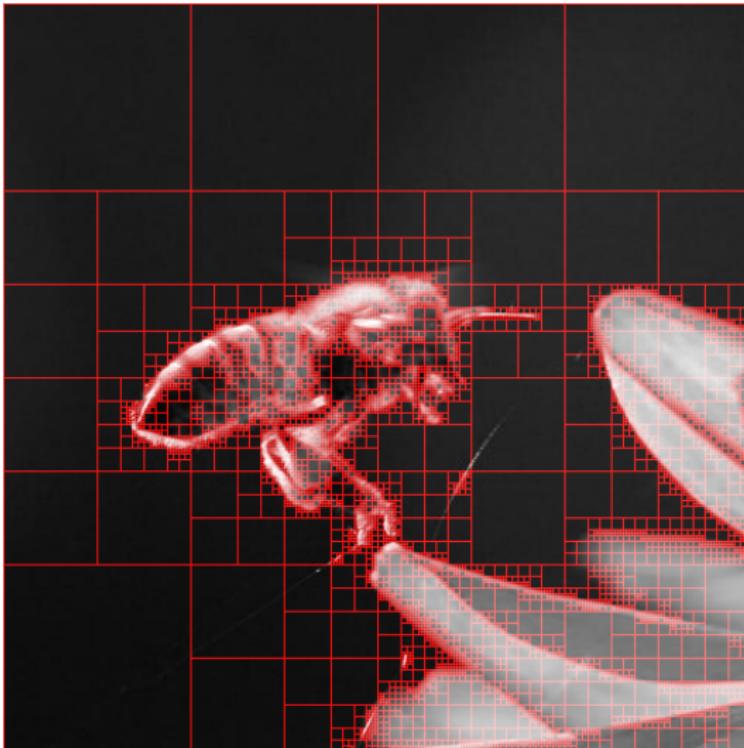
- ① **Initialisation** : une partition initiale (tous les pixels ou régions constituées de pixels connexes de même niveau de gris), ou un ensemble de germes ;
- ② **Merging** : tant que c'est possible, réunion des paires de régions qui vérifient une propriété d'homogénéité donnée (contraste, variance...) ou réunion des paires de régions dont le regroupement améliore l'"énergie" de segmentation.

Partage de région (split) : on découpe jusqu'à ce que toutes les régions vérifient une propriété donnée ou tant que l'énergie décroît.
Existence d'algorithmes hybrides "split and merge".

Remarques :

- Algorithmes en général non basés sur des modèles théoriques, dépendant d'un grand nombre de **paramètres (seuils) heuristiques** et implicites.
- Mais certains de ces algorithmes ont une **énergie "sous-jacente"** ou explicite et peuvent se reformuler de manière variationnelle (minimisation d'une énergie).
- Les paramètres des méthodes sont ainsi transformés en poids devant les différents termes de la fonctionnelle à minimiser. Paramètre = notion d'échelle.

Algorithmes de croissance de région ou de croissance de bords



Décomposition en *quadtree*

Algorithme de Beaulieu et Goldberg (1989)

- ① Initialisation : régions = tous les pixels
- ② On réunit les deux régions O_i et O_j telles que $Var(O_i \cup O_j) - Var(O_i) - Var(O_j)$ est minimale.
- ③ L'algorithme s'arrête quand on a le nombre de régions désiré.

[J. BEAULIEU and M. GOLDBERG]. Hierarchy in picture segmentation : a stepwise optimization approach. IEEE on Trans. on Patt. Anal. and Mach. Int., 11(2) : 150-163, 1989.

Un exemple simple

Algorithme de Beaulieu et Goldberg (1989)

- ① Initialisation : régions = tous les pixels
- ② On réunit les deux régions O_i et O_j telles que $Var(O_i \cup O_j) - Var(O_i) - Var(O_j)$ est minimale.
- ③ L'algorithme s'arrête quand on a le nombre de régions désiré.

Revient à minimiser l'énergie

$$E((O_i)_i) = \sum_i Var(O_i) \text{ sous la contrainte } Card((O_i)_i) = c.$$

Compromis cardinal / variance.

Fonctionnelle "sans seuil" à minimiser : $E((O_i)_i) = \sum_i Var(O_i) + \lambda Card((O_i)_i)$. λ est le paramètre d'échelle. Condition d'arrêt $Var(O_i \cup O_j) - Var(O_i) - Var(O_j) < \lambda$

Pas de contrôle de la régularité des contours !

[J. BEAULIEU and M. GOLDBERG]. Hierarchy in picture segmentation : a stepwise optimization approach. IEEE on Trans. on Patt. Anal. and Mach. Int., 11(2) : 150-163, 1989.

Energie naturelle associée à toute segmentation (u, K) de l'image u_0 , qui mesure

- la quantité d'information contenue dans u version régularisée de u_0 ;
- la longueur et la régularité des bords K .

$$E(u, K) = \beta \mathcal{L}(K) + \int_{\Omega \setminus K} |\nabla u|^2.$$

Fonctionnelle de Mumford et Shah : énergie multiéchelle à minimiser en (u, K)

$$F(u, K) = \underbrace{\beta \mathcal{L}(K) + \alpha \int_{\Omega \setminus K} |\nabla u|^2}_{\text{coût de la segmentation}} + \underbrace{\int_{\Omega \setminus K} (u - u_0)^2}_{\text{attache aux données}}.$$

Minimiser F revient à trouver u régulière qui soit proche de u_0 sans avoir trop de bords.

Formulation variationnelle : cas particulier

Si u supposée **constante sur chaque région**, revient à minimiser

$$E(K) = \beta \mathcal{L}(K) + \int_{\Omega \setminus K} (u - u_0)^2,$$

où u est constante sur chaque région connexe ($\bar{u}_i = u|_{O_i} = \frac{1}{|O_i|} \int_{O_i} u_0$).

- terme $\int_{\Omega \setminus K} (u - u_0)^2 dx$ équivalent du terme $\sum_i Var(O_i)$ dans la méthode de croissance de régions de Beaulieu et Goldberg.

Paramètre d'échelle β

- petit \Rightarrow grand nombre de bords (segmentation fine)
- grand \Rightarrow faible nombre de bords (segmentation grossière).

But : trouver le contour des objets présents dans l'image

Principe : à partir d'un contour initial grossier, faire évoluer la courbe pour qu'elle se rapproche du contour de l'objet (d'où le nom "snakes").

Energie d'un contour se décompose en

- une énergie externe qui mesure l'adéquation du contour aux données (gradient de l'image par ex)
- une énergie interne qui mesure la régularité du contour.

→ **Sera vu en détail en IM04**